



Université
Paris Cité

DÉPARTEMENT SCIENCES DES DONNÉES

RAPPORT FINAL - STATISTIQUE

LES RÉSULTATS D'UNE COMPÉTITION DE SKATEBOARD



SOMMAIRE

1. Introduction

2. Présentation des données

2.1 Présentation des variables

2.2 Statistiques descriptives

3. Analyses avancées

3.1 Corrélation entre l'âge et la performance

3.2 Corrélation du genre sur la performance

3.3 Corrélation du classement en demi final sur le classement final

4. Conclusion

4.1 Conclusion scientifique

4.2 Conclusion méthodologique

5. Table des illustrations

6. Lexique

7. Annexe

1. Introduction

Ce rapport présente un projet d'analyse statistique réalisé à partir d'un jeu de données issu d'une compétition de skateboard. L'objectif est d'identifier les facteurs pouvant être corrélés aux résultats obtenus par les participants.

Le fichier de données contient 219 observations, représentant des participations uniques à une manche de compétition.

Un même athlète peut apparaître plusieurs fois s'il a participé à plusieurs rounds (quarterfinal, semifinal, final). Plusieurs variables sont renseignées pour chaque individu : nom, prénom, sexe, division (catégorie de participation), ainsi que les scores obtenus dans différentes épreuves.

Ces données ont été collectées dans le cadre d'un événement sportif, vraisemblablement dans le but d'enregistrer les performances des participants. Elles permettent aujourd'hui d'effectuer une étude statistique visant à explorer les déterminants de la performance dans ce contexte.

Même si le domaine du skateboard est peu familier, il se prête à une analyse rigoureuse grâce aux nombreuses variables disponibles. Nous nous intéressons ici à la corrélation potentielle de certaines variables (sexe, division, performances partielles...) sur le résultat global ou les scores les plus représentatifs de la compétition.

Pour créer une base propre et exploitable nous avons d'abord inspecter notre jeu de données pour voir s'il y avait des données manquantes ou incohérentes. Avant d'analyser les données, il est essentiel d'effectuer un nettoyage rigoureux afin de garantir la qualité et la fiabilité des résultats. Les données brutes ont été importés dans R à l'aide la fonction *read_excel()*. Une fois les données chargés une première phase de nettoyage a été réalisé. (voir annexe 1)

Dans notre projet, nous avons d'abord identifié les valeurs manquantes. Certaines données n'étaient pas enseignées, notamment certains scores attribués par les juges et certains totaux. Pour y remédier nous avons les avons complétés selon les règles de calcules.

En parallèle, nous avons également procédé à la construction de nouvelles variables afin d'enrichir notre base et faciliter l'interprétation. Les variables créées sont :

- Âge des participants, calculé à partir de leur date de naissance (annexe 2)
- Classement par manche, pour observer les performances à chaque étape (annexe 3)
- Classement global, qui permet une évaluation globale des participants sur l'ensemble des manches (annexe 4)

Ces transformations nous ont permis d'obtenir une base de données plus cohérente, complète et exploitable pour l'analyse statistique et la modélisation. Une base propre est un prérequis indispensable pour garantir la validité de nos propos.

À partir de cette base, nous nous posons la question suivante :
Quels facteurs sont en corrélation avec les résultats de la compétition ?

L'objectif est donc d'identifier les variables les plus liées à la performance, à travers des analyses statistiques exploratoires et éventuellement des modélisations. Cette étude permettra de mieux comprendre les relations entre les caractéristiques des athlètes et leurs performances mesurées.

2. Présentation des données

2.1 Présentation des variables

Le jeu de données utilisé dans ce projet contient 219 observations, chacune correspondant à la performance d'un athlète lors d'un round de compétition de skateboard. Ce fichier regroupe à la fois des informations personnelles et des résultats détaillés pour chaque participant. Il est important de noter qu'un même athlète peut apparaître plusieurs fois dans le fichier s'il a participé à plusieurs manches ou rounds de la compétition.

Les variables présentes dans la base sont de deux types : qualitatives et quantitatives. Les variables qualitatives comprennent notamment le nom et prénom de l'athlète (variable Athlète), la date de naissance (DOB), ainsi que la date à laquelle s'est déroulée la compétition (Date compétition). Ces trois variables sont de nature qualitative nominale, car elles ne possèdent aucun ordre logique. La variable Division permet de regrouper les participants selon leur tranche d'âge et leur sexe (par exemple : "Street garçons U17", "Street femmes +17"). Elle est également qualitative nominale. Enfin, la variable Round, qui précise la manche de la compétition (qualification, demi-finale, finale), est une variable qualitative ordinale, car les étapes suivent un ordre logique.


Les variables quantitatives continues du jeu de données sont principalement liées aux performances sportives. La variable Total indique le score global obtenu par un athlète pour un round donné. Les variables Score_1 à Score_7 représentent les scores obtenus lors des différentes figures réalisées : Score_1 et Score_2 correspondent aux deux runs, tandis que Score_3 à Score_7 correspondent aux cinq tricks. Pour chaque figure, on retrouve également le détail des notes attribuées par les juges, dans les variables Score_1_judges à Score_7_judges, au format de cinq valeurs séparées par des virgules.

Un run est une prestation d'environ 45 secondes durant laquelle l'athlète enchaîne librement des figures sur le parcours. Cette performance est notée par cinq juges, chacun attribuant une note individuelle. À l'inverse, un trick est une figure isolée réalisée en une seule tentative, qui est elle aussi notée par les cinq juges. Pour chaque run ou trick, le score final est calculé en supprimant la meilleure et la pire note parmi les cinq, puis en prenant la moyenne des trois restantes. Ce système permet de limiter l'impact des jugements extrêmes.

Le calcul du score total dépend de la phase de la compétition. En quart de finale et en demi-finale, seul le meilleur des deux runs est conservé : le score total est donc égal à la meilleure note entre Score_1 et Score_2. En finale, deux méthodes sont appliquées selon l'âge du participant. Pour les athlètes de 17 ans et plus, le score total correspond à la somme du meilleur run (entre Score_1 et Score_2) et des deux meilleurs tricks parmi les scores Score_3 à Score_7. Pour les athlètes de moins de 17 ans, le score total correspond à la somme du meilleur run (entre Score_1 et Score_2) et du meilleur trick parmi Score_3, Score_4 et Score_5.

2.2 Statistiques descriptives

Graphique 1 : Répartition des athlètes par tranche d'âge




Une première analyse descriptive du fichier permet de mieux cerner la composition de l'échantillon. La majorité des participants sont de jeunes athlètes : les 16–17 ans sont les plus représentés, suivis des 13–15 ans. Cette répartition suggère que la compétition attire particulièrement les adolescents, avec une prédominance dans les tranches d'âge les plus jeunes. L'âge moyen des participants est de 16,3 ans, ce qui confirme la jeunesse globale de l'échantillon.

```

192 # 1. Calcul de la moyenne d'âge
193 age_moyen <- mean(data_separee$Age, na.rm = TRUE)
194
195 # 2. Création de l'histogramme avec la barre et le texte
196 ggplot(data = data_separee) +
197   aes(x = Age) +
198   geom_histogram(fill = "steelblue4", color = "black", bins = 30) +
199   geom_vline(aes(xintercept = age_moyen),
200             color = "red",
201             linetype = "dashed",
202             size = 1) +
203   annotate("text",
204           x = age_moyen,
205           y = 0, # tout en bas de l'histogramme
206           label = paste0(round(age_moyen, 1)),
207           color = "red",
208           vjust = 2.7,
209           angle = 0, # texte vertical pour suivre la ligne
210           size = 4) +
211   labs(title = "Répartition de l'âge",
212        x = "Âge",
213        y = "Effectif")
214

```

Graphique 2 : Répartition des athlètes selon le genre




Concernant le genre, la compétition est majoritairement masculine, avec environ 70 % d'hommes contre 30 % de femmes. Ce déséquilibre montre une participation plus forte des garçons et des hommes dans cet événement sportif. Cela peut refléter une tendance générale dans la pratique du skateboard à ce niveau de compétition.

```

219
220 ggplot(data = data_separee %>% distinct(Athlete, .keep_all = TRUE)) +
221   aes(x = Genre) +
222   geom_bar(fill = "pink", color = "black", width = 0.5) +
223   geom_text(stat = "count",
224             aes(label = paste0(..count.., " (",
225                               round(..count.. / sum(..count..) * 100, 1), "%)")),
226             vjust = -0.5,
227             color = "black",
228             size = 4) +
229   labs(title = "Répartition du genre",
230        x = "Genre",
231        y = "Effectif")

```

Graphique 3 : Répartition des athlètes selon la division



```

234
235 # Calculer les effectifs distincts par Division
236 data_distinct <- data_separée %>%
237   distinct(Athlete, Division) %>% # on garde une ligne par athlète par division
238   count(Division) %>%           # compter le nombre d'athlètes uniques par division
239   mutate(Pourcentage = n / sum(n) * 100)
240
241 # Plot avec les effectifs distincts
242 ggplot(data_distinct) +
243   aes(y = fct_reorder(Division, n, .fun = identity), x = n) +
244   geom_bar(stat = "identity", fill = "purple", color = "black", width = 0.7) +
245
246   geom_text(aes(label = paste0(n, "\n(", round(Pourcentage, 1), "%)")),
247             hjust = 1.1,
248             color = "white",
249             size = 4) +
250
251   labs(title = "Répartition selon la division (athlètes distincts)",
252        x = "Effectif",
253        y = "Division") +
254   theme_minimal()
255
256

```

La répartition par division met en évidence une forte présence des jeunes garçons dans la compétition. En effet, 37,5 % des athlètes participent dans la catégorie *Street garçons U17*, 32,9 % dans *Street hommes +17*, 20,4 % dans *Street filles U17*, et seulement 9,2 % dans *Street femmes +17*. Cette distribution souligne à la fois la jeunesse de l'échantillon et la prédominance des participants masculins, notamment dans la catégorie U17.

Les tendances observées sont illustrées ci-dessus à l'aide de graphiques présentant la répartition des participants selon l'âge, le sexe et la division. Ces visualisations permettent d'identifier les éventuels déséquilibres dans l'échantillon et de mieux comprendre le contexte dans lequel s'inscrit l'analyse statistique à venir.

3. Analyses avancées

3.1 Corrélation entre l'âge et la performance

Dans un premier temps, nous avons souhaité déterminer s'il y avait une corrélation significative entre l'âge et les performances des athlètes lors de la compétition. Pour cela, nous avons analysé le classement moyen des participants en fonction de leur tranche d'âge, en distinguant les deux divisions principales : Street U17 et Street +17. Le classement a été utilisé comme indicateur de performance, en considérant que plus le classement est bas, meilleure est la performance.


Il est important de noter que nous séparerons systématiquement les catégories +17 et U17 dans nos analyses, car les notations ne sont pas les mêmes entre ces deux divisions, ce qui rendrait les comparaisons directes peu pertinentes et biaisées.

Les participants ont été regroupés selon des tranches d'âge spécifiques. Pour la catégorie Street U17, les tranches étaient : 5–10 ans, 11–13 ans et 14–16 ans. Pour la catégorie Street +17, les tranches étaient : 14–16 ans, 17–20 ans, 21–25 ans et 26–36 ans.

Pour chaque groupe d'âge, nous avons calculé le classement moyen, ainsi que l'écart-type afin de représenter la dispersion des résultats à l'aide de barres d'erreur sur les graphiques.

Deux graphiques ont été produits :

- **Graphique 4 : Classement moyen par tranche d'âge – *Street +17*, tous genres**




```

762 # Graphique
763 ggplot(classement_stats, aes(x = Tranche_Age, y = Classement_Moyen, group = 1)) +
764   geom_point(size = 4, color = "darkorange") +
765   geom_line(color = "darkorange", size = 1) +
766   geom_errorbar(aes(ymin = Classement_Moyen - Ecart_Type,
767                     ymax = Classement_Moyen + Ecart_Type),
768                 width = 0.2, color = "gray40") +
769   scale_y_reverse() +
770   labs(
771     title = "Classement moyen par tranche d'âge (+17, tous genres)",
772     x = "Tranche d'âge",
773     y = "Classement moyen ± écart-type"
774   ) +
775   theme_minimal()

```

- Graphique 5 : Classement moyen par tranche d'âge – *Street U17, tous genres*



Graphique 4 : *Street +17, tous genres*

Ce graphique met en évidence une évolution variable de la performance en fonction de l'âge. Les athlètes âgés de 14 à 16 ans obtiennent les meilleurs classements moyens, autour de 14 ce qui indique une performance relativement élevée. En revanche, les athlètes âgés de 17 à 20 ans ont des classements moyens un peu plus élevés, respectivement autour de 18 et 23, traduisant une baisse de performance. Fait surprenant, les 26–36 ans retrouvent un bon niveau, avec un classement moyen d'environ 15.

Ainsi, la performance semble progresser au début de l'adolescence, atteindre un pic précoce chez les 14–16 ans, puis diminuer chez les jeunes adultes, avant de remonter légèrement chez les adultes plus âgés. Cette évolution non linéaire pourrait s'expliquer par une combinaison de facteurs : maturité physique précoce, expérience compétitive, différences d'intensité d'entraînement ou gestion des efforts.

Graphique 5 : *Street U17, tous genres*

Le deuxième graphique, centré sur les athlètes de moins de 17 ans, montre une progression plus régulière. Les enfants âgés de 5 à 10 ans affichent des classements moyens élevés, autour de 21, traduisant des performances plus faibles. Les 11–13 ans présentent une nette amélioration, avec un classement moyen autour de 15. Les 14–16 ans restent dans une dynamique de performance similaire aux 5-10 ans, mais avec une dispersion plus élevée.

Ces résultats suggèrent que les performances augmentent de façon marquée entre 5 et 13 ans, probablement en lien avec le développement physique, la coordination et l'acquisition de compétences techniques. Toutefois, à partir de 14 ans, cette progression semble ralentie, ce

qui peut indiquer un seuil d'apprentissage atteint ou des écarts de niveau plus hétérogènes dans cette tranche d'âge.

Les deux graphiques mettent en évidence une influence réelle de l'âge sur la performance, bien que cette relation ne soit pas linéaire.

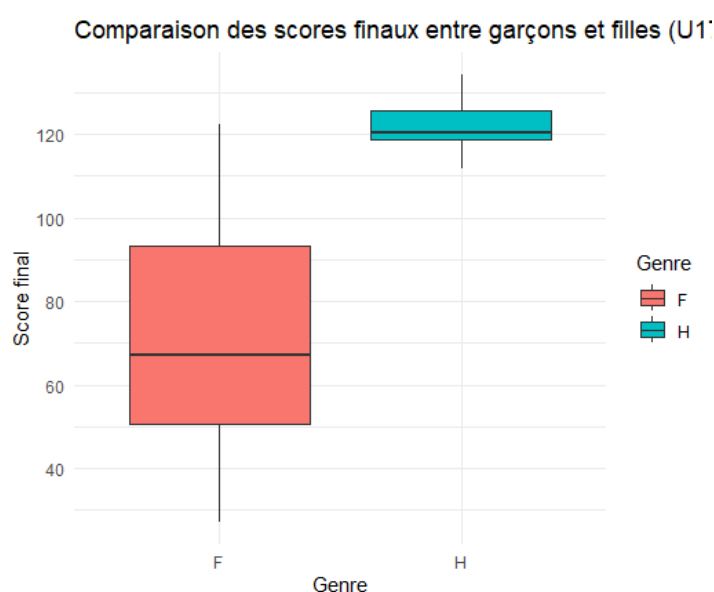
Chez les athlètes +17, la meilleure performance moyenne est observée précocement chez les 14–16 ans, suivie d'une baisse chez les 17–25 ans, puis d'un léger regain chez les 26–36 ans.

Il est toutefois important de souligner que les barres d'erreur sont importantes dans plusieurs tranches d'âge. Cela signifie que l'âge n'explique pas à lui seul la performance, car il y a des fluctuations internes même si les barres d'erreur suivent la tendance des droites. D'autres facteurs comme l'entraînement, l'expérience en compétition, les conditions physiques du jour ou la gestion du stress peuvent influencer fortement les résultats.

3.2 Corrélation du genre sur la performance

Dans un second temps, nous avons analysé l'effet du genre sur la performance en comparant les résultats des athlètes masculins et féminins en final, dans deux grandes catégories : les moins de 17 ans (*U17*) et les 17 ans et plus (*U+17*). Pour cette analyse, les indicateurs statistiques de tendance centrale (moyenne, médiane) et de dispersion (minimum, maximum, écart-type, amplitude) ont été utilisés. Deux graphiques permettent de visualiser ces différences de manière plus intuitive.

Comparaison des performances entre femmes et hommes lors de la finale– U17




```

583
584 # Filtrer la finale U17 (garçons et filles)
585 data_u17_finale <- data_separée %>%
586   filter(Round == "Final", Division %in% c("street garçons u 17", "street filles u 17"))
587
588 # Visualisation Score Total par Genre
589 ggplot(data_u17_finale, aes(x = Genre, y = Total, fill = Genre)) +
590   geom_boxplot() +
591   labs(
592     title = "Comparaison des scores finaux entre garçons et filles (U17)",
593     x = "Genre",
594     y = "Score final"
595   ) +
596   theme_minimal()
597

```

Chez les U17, les résultats indiquent une différence nette entre les deux genres. Les athlètes masculins affichent des performances globalement plus élevées en final. En effet, le score minimum des garçons (112) dépasse le maximum obtenu par les filles (120), ce qui signifie que même les moins bons garçons performant mieux que les meilleures filles dans cette catégorie. La médiane des garçons est de 120, contre 67 pour les filles, et l'amplitude est bien plus réduite (22 contre 92), ce qui traduit des performances plus homogènes et concentrées chez les garçons.

Comparaison des performances entre femmes et hommes – +17



Cette tendance se confirme chez les U+17. Les hommes présentent une moyenne de 250 et une médiane de 252, contre une moyenne de 176 et une médiane de 169 chez les femmes. L'écart-type, légèrement plus élevé chez les hommes (28,4 contre 22,9), indique une plus grande variabilité, mais cela ne remet pas en cause l'écart général de niveau. Là encore, le minimum des hommes (209) dépasse le maximum des femmes (216), ce qui souligne la domination masculine sur l'ensemble de la distribution.

Dans l'ensemble, ces résultats montrent que le genre influence significativement les performances, dans les deux tranches d'âge étudiées. Les hommes obtiennent des scores nettement supérieurs à ceux des femmes, avec une dispersion parfois plus faible (chez les U17), parfois plus grande (chez les U+17), mais toujours avec des indicateurs centraux largement en faveur des athlètes masculins. Ces écarts peuvent s'expliquer par des différences

physiologiques (force musculaire, explosivité), des disparités dans les conditions d'entraînement, ou encore des facteurs socioculturels affectant la pratique sportive selon le genre.

3.3 Corrélation du classement en demi-finale sur le classement final

Nous avons cherché à déterminer si le classement obtenu en demi-finale permettait de prédire le classement final. Pour cela, nous avons analysé séparément les quatre catégories suivantes : femmes +17, hommes +17, filles U17 et garçons U17. L'objectif était de visualiser les liens potentiels entre les deux classements à l'aide de nuages de points, et de modéliser ces relations par des courbes de régression polynomiale.


Le choix du degré du polynôme s'est appuyé sur le critère d'information d'Akaike (AIC). Ce critère permet de sélectionner le modèle le plus adapté en tenant compte à la fois de la qualité de l'ajustement et de la complexité du modèle. Nous présentons ci-dessous le tableau des valeurs d'AIC pour la catégorie femmes +17, seule pour illustrer la démarche. La même procédure a été appliquée aux autres catégories.

Tableau AIC – Modèles de régression polynomiale (Femmes +17)	
degre	AIC
1	39,40305
2	33,81873
3	34,72026
4	34,11248
5	34,25413

```

542 # Étape 3 : Modèles polynomiaux degré 1 à 5
543 mod1 <- lm(Rank_Total ~ poly(Classement_par_Manche, 1), data = semi_finale_finalistes_hommes)
544 mod2 <- lm(Rank_Total ~ poly(Classement_par_Manche, 2), data = semi_finale_finalistes_hommes)
545 mod3 <- lm(Rank_Total ~ poly(Classement_par_Manche, 3), data = semi_finale_finalistes_hommes)
546 mod4 <- lm(Rank_Total ~ poly(Classement_par_Manche, 4), data = semi_finale_finalistes_hommes)
547 mod5 <- lm(Rank_Total ~ poly(Classement_par_Manche, 5), data = semi_finale_finalistes_hommes)
548
549 # Comparaison des AIC
550 aic_df_hommes <- data.frame(
551   Degré = 1:5,
552   AIC = c(AIC(mod1), AIC(mod2), AIC(mod3), AIC(mod4), AIC(mod5))
553 )
554
555 print(aic_df_hommes)

```




```


556 # Ajuster le modèle polynomial de degré 1 (régression linéaire simple)
557 modele_deg1_hommes <- lm(Rank_Total ~ poly(Classement_par_Manche, 1, raw = TRUE), data = semi_finale_finalistes_hommes)
558
559 # Extraire le R²
560 r2_deg1_hommes <- summary(modele_deg1_hommes)$r.squared
561 r2_text_deg1_hommes <- paste0("R² = ", round(r2_deg1_hommes, 3))
562
563 # Tracer le nuage de points + courbe polynomiale degré 1 + R²
564 ggplot(data = semi_finale_finalistes_hommes) +
565   aes(x = Classement_par_Manche, y = Rank_Total) +
566   geom_point(color = "steelblue") +
567   geom_smooth(method = "lm", formula = y ~ poly(x, 1, raw = TRUE), se = FALSE, color = "red", size = 1) +
568   annotate("text",
569     x = max(semi_finale_finalistes_hommes$Classement_par_Manche) * 0.7,
570     y = max(semi_finale_finalistes_hommes$Rank_Total) * 0.9,
571     label = r2_text_deg1_hommes, color = "red", size = 5) +
572   scale_x_continuous(breaks = scales::pretty_breaks(), labels = function(x) as.integer(x)) +
573   scale_y_continuous(breaks = scales::pretty_breaks(), labels = function(y) as.integer(y)) +
574   labs(
575     title = "classement en demi-finale vs classement final (hommes +17) - Modèle degré 1",
576     x = "classement en demi-finale",
577     y = "classement final"
578   ) +
579   theme_minimal()
580

```


Pour la catégorie femmes +17, la courbe ajustée est un polynôme de degré 2 (parabole inversée), justifié par le plus faible AIC observé. Le coefficient de détermination R^2 est de 0,72, ce qui indique une relation modérément forte. Cette relation n'est pas strictement linéaire : les athlètes ayant un classement intermédiaire en demi-finale peuvent finir mieux classées que celles arrivées premières. Cela montre que la performance en demi-finale ne garantit pas nécessairement un bon classement en finale, avec des renversements possibles. Cependant, il est important de noter que les athlètes du top 3 en demi-finale conservent leur position dans le top 3 final, ce qui souligne une certaine stabilité des meilleures performances.



Chez les filles U17, la relation est clairement linéaire. Le modèle retenu est une droite, avec un R^2 élevé de 0,814. Cela signifie que le classement en demi-finale est fortement corrélé au classement final. Les meilleures en demi-finale tendent à le rester en finale. Cette stabilité suggère une continuité des performances, avec peu de surprises entre les deux phases.



Pour les garçons U17, la courbe ajustée est un polynôme de degré 5, présentant une forme très ondulée. Le R^2 est exceptionnellement fort (0,955), indiquant que le modèle explique très bien la variabilité des données. Toutefois, la forme irrégulière de la courbe révèle une relation complexe : certains athlètes très bien classés en demi-finale peuvent chuter en finale, tandis que d'autres remontent fortement. Cette variabilité pourrait s'expliquer par une instabilité des performances due à la pression ou à l'irrégularité des runs.



Enfin, chez les hommes +17, la courbe ajustée est une droite, mais la relation reste faible avec un R^2 de seulement 0,227. Le nuage de points est très dispersé, ce qui montre qu'il n'y a que peu de lien entre le classement en demi-finale et celui en finale. Dans cette catégorie, le classement en demi-finale semble peu déterminant. Cela peut s'expliquer par des stratégies de gestion de l'effort ou un niveau de compétition très homogène.

Les résultats montrent que la corrélation du classement en demi-finale sur le classement final varie fortement selon les catégories.

Chez les femmes +17, la relation est modérée et non linéaire : être bien classée en demi-finale ne garantit pas de finir en tête lors de la finale. Le modèle parabolique (degré 2) reflète bien cette tendance, avec un R^2 de 0,72. On observe donc des retournements possibles entre les deux phases.

Pour les filles U17, la corrélation est forte et linéaire. Les athlètes les mieux classées en demi-finale conservent généralement leur position en finale. La stabilité des résultats montre une logique de continuité dans les performances, avec peu de surprises. Cela se traduit par un R^2 élevé de 0,814.

En revanche, chez les garçons U17, la relation est très forte ($R^2 = 0,955$) mais non linéaire. Le modèle retenu, un polynôme de degré 5, traduit une grande variabilité dans les classements : certains jeunes très bien classés en demi-finale chutent en finale, et inversement. Cette instabilité peut refléter une forte pression, une variabilité des performances, ou des différences de stratégie.

Enfin, chez les hommes +17, la relation est faible ($R^2 = 0,227$). Le classement en demi-finale ne permet pas de prédire de façon fiable le classement final. Le lien, bien que légèrement croissant, reste très dispersé. Cela peut s'expliquer par des stratégies de gestion de l'effort, une forte concurrence ou une homogénéité de niveau rendant les écarts moins significatifs.

4. Conclusion

4.1 Conclusion scientifique

L'analyse des données a permis de répondre à la problématique suivante : **Quels facteurs sont en corrélation avec les résultats de la compétition ?**

Corrélation de l'âge :

Les performances évoluent avec l'âge. Chez les athlètes de moins de 17 ans, la performance s'améliore jusqu'à environ 14–16 ans, puis tend à se stabiliser. Chez les +17 ans, les meilleures performances sont observées entre 21 et 25 ans, suivies d'un léger déclin. Ce constat reflète les phases de développement physique, technique et d'expérience.

Corrélation du genre :

Le genre est un facteur clé influençant les résultats. Les hommes ont des performances significativement supérieures aux femmes dans toutes les catégories, avec des écarts notables tant sur les performances moyennes que sur les extrêmes. Ces différences peuvent s'expliquer par des facteurs physiologiques, ainsi que par des disparités d'entraînement ou d'accès à la compétition.

Relation entre classement en demi-finale et classement final :

La corrélation entre le classement en demi-finale et en finale dépend de la catégorie :

- Chez les filles U17, la relation est forte et linéaire, ce qui signifie que les performances se maintiennent.
- Chez les femmes +17, la relation est modérément forte et non linéaire, indiquant que les premières en demi-finale ne sont pas toujours premières en finale.
- Chez les garçons U17, la relation est très forte mais complexe, avec des fluctuations importantes.
- Chez les hommes +17, la corrélation est faible, suggérant que le classement en demi-finale est peu prédictif du classement final, possiblement à cause de stratégies ou de forte concurrence.

Réponse à la problématique :

Les résultats montrent que l'âge, le genre et le classement en demi-finale sont des facteurs en corrélation avec les résultats de la compétition, mais leur influence varie selon les catégories. L'âge reflète le développement physique et l'expérience, le genre souligne des différences physiologiques et sociales, tandis que le classement en demi-finale est plus ou moins prédictif selon le groupe d'athlètes.

4.2 Conclusion méthodologique

Au-delà des résultats statistiques, ce projet nous a confrontés à plusieurs difficultés techniques et méthodologiques. L'une des premières étapes a été de traiter des données incomplètes ou incohérentes : certains scores manquaient, et plusieurs totaux n'étaient pas renseignés. Nous avons dû appliquer des formules de calcul personnalisées dans R pour reconstruire les scores à partir des notes des juges, ce qui a nécessité une bonne compréhension des règles de notation propres à chaque catégorie d'âge.

Par ailleurs, la création de nouvelles variables (âge, classement global, écarts entre juges...) a exigé une structuration précise de la base. L'une des difficultés majeures a été de garder une cohérence entre les lignes représentant différentes participations d'un même athlète (quarterfinal, semifinal, final), sans fausser les moyennes ou doubler les informations.

Enfin, la visualisation des données a aussi demandé un travail minutieux : choisir des graphiques adaptés à chaque type d'analyse (boxplots, régressions, courbes par catégorie), les rendre lisibles et interprétables, et parfois ajuster les échelles manuellement. L'interprétation des modèles de régression (linéaires ou polynomiaux) a nécessité une compréhension du choix des modèles via l'AIC, et de l'interprétation des coefficients de détermination (R^2).

Ce travail de préparation, bien que fastidieux, a été indispensable pour garantir la fiabilité et la pertinence de nos analyses.

En termes de pistes d'amélioration, mieux structurer le code aurait pu être un moyen de gagner du temps car celui-ci devenait long et désorganisé, on aurait dû commenter dès le début les scripts. En somme, cette étude a permis de répondre à la problématique posée tout en développant des compétences précieuses en gestion de données, analyse statistique et réflexion critique sur les limites et les perspectives d'un projet de recherche appliquée.

5. Table des illustrations

Numéro	Titre	Type	Page
Graphique 1	Répartition des athlètes par tranche d'âge	Graphique	6
Graphique 2	Répartition des athlètes selon le genre	Graphique	7
Graphique 3	Répartition des athlètes selon la division	Graphique	8
Graphique 4	Classement moyen par tranche d'âge – Street +17	Graphique	10
Graphique 5	Classement moyen par tranche d'âge – Street U17	Graphique	10
Graphique 6	Comparaison des performances entre femmes et hommes – Finale U17	Graphique	12
Graphique 7	Comparaison des performances entre femmes et hommes – +17	Graphique	13

Numéro	Titre	Type	Page
Tableau 1	Valeurs AIC pour modélisation (exemple Femmes +17)	Tableau	14
Graphique 8	Classement en demi-finale vs classement en finale – Femmes +17	Graphique	14
Graphique 9	Classement en demi-finale vs classement en finale – Filles U17	Graphique	15
Graphique 10	Classement en demi-finale vs classement en finale – Garçons U17	Graphique	16
Graphique 11	Classement en demi-finale vs classement en finale – Hommes +17	Graphique	16

6. Lexique

AIC (Akaike Information Criterion)

Critère utilisé pour comparer des modèles statistiques. Il mesure la qualité d'un modèle en prenant en compte la complexité (nombre de paramètres) et la capacité à ajuster les données. Un AIC plus faible indique un meilleur compromis entre complexité et qualité d'ajustement.

Run

Séquence d'exécution d'une série de figures ou de mouvements effectués par un athlète dans une compétition. Un run correspond à un passage complet sur le parcours ou la zone de performance, durant lequel l'athlète enchaîne différents tricks.

Street

Discipline ou catégorie dans laquelle les athlètes exécutent leurs performances, souvent sur un parcours urbain ou inspiré du street, avec des éléments comme des marches, rampes, rails, etc.

Trick

Manœuvre technique ou figure spécifique réalisée par un athlète lors d'un run. Les tricks

peuvent inclure des sauts, rotations, flips, slides, ou toute autre action acrobatique ou technique destinée à impressionner les juges et marquer des points.

U17

Catégorie d'âge désignant les athlètes de moins de 17 ans.

+ 17

Catégorie d'âge désignant les athlètes de plus de 17 ans, attention car un athlète de moins de 17 ans peut être surclassé et être dans cette catégorie.

7. Annexe

Annexe 1: Chargement des données et nettoyage et valeurs manquantes

```

1 setwd("Z:/R")
2 .libPaths("Packages")
3
4 # Installation des packages
5 install.packages("tidyr")
6 install.packages("dplyr")
7 library(tidyverse)
8 library(skimr)
9 library(questionr)
10 library(ggstats)
11 library(tidyr)
12 library(dplyr)
13 library(readxl)
14 library(scales)
15 # ouverture de notre fichier excel
16 data <- read_excel("Z:/R/Projet/Championnat_de_France_Skateboard_Street_2024.xlsx")
17 head(data)
18
19 # Séparer la colonne scores juges en plusieurs colonnes
20 data_separée <- data %>%
21   mutate(
22     score_1_judges = gsub("Runs: ", "", score_1_judges),
23     score_2_judges = gsub("Runs: ", "", score_2_judges),
24     score_3_judges = gsub("Tricks: ", "", score_3_judges),
25     score_4_judges = gsub("Tricks: ", "", score_4_judges),
26     score_5_judges = gsub("Tricks: ", "", score_5_judges),
27     score_6_judges = gsub("Tricks: ", "", score_6_judges),
28     score_7_judges = gsub("Tricks: ", "", score_7_judges)
29   ) %>%
30   separate(score_1_judges, into = c("score1.1", "score1.2", "score1.3", "score1.4", "score1.5"), sep = ",") %>%
31   separate(score_2_judges, into = c("score2.1", "score2.2", "score2.3", "score2.4", "score2.5"), sep = ",") %>%
32   separate(score_3_judges, into = c("score3.1", "score3.2", "score3.3", "score3.4", "score3.5"), sep = ",") %>%
33   separate(score_4_judges, into = c("score4.1", "score4.2", "score4.3", "score4.4", "score4.5"), sep = ",") %>%
34   separate(score_5_judges, into = c("score5.1", "score5.2", "score5.3", "score5.4", "score5.5"), sep = ",") %>%
35   separate(score_6_judges, into = c("score6.1", "score6.2", "score6.3", "score6.4", "score6.5"), sep = ",") %>%
36   separate(score_7_judges, into = c("score7.1", "score7.2", "score7.3", "score7.4", "score7.5"), sep = ",")
37
38
39 # Mettre les cases en version numérique
40 data_separée[, c("score1.1", "score1.2", "score1.3", "score1.4", "score1.5",
41                 "score2.1", "score2.2", "score2.3", "score2.4", "score2.5",
42                 "score3.1", "score3.2", "score3.3", "score3.4", "score3.5",
43                 "score4.1", "score4.2", "score4.3", "score4.4", "score4.5",
44                 "score5.1", "score5.2", "score5.3", "score5.4", "score5.5",
45                 "score6.1", "score6.2", "score6.3", "score6.4", "score6.5",
46                 "score7.1", "score7.2", "score7.3", "score7.4", "score7.5")] <-
47   lapply(data_separée[, c("score1.1", "score1.2", "score1.3", "score1.4", "score1.5",
48                           "score2.1", "score2.2", "score2.3", "score2.4", "score2.5",
49                           "score3.1", "score3.2", "score3.3", "score3.4", "score3.5",
50                           "score4.1", "score4.2", "score4.3", "score4.4", "score4.5",
51                           "score5.1", "score5.2", "score5.3", "score5.4", "score5.5",
52                           "score6.1", "score6.2", "score6.3", "score6.4", "score6.5",
53                           "score7.1", "score7.2", "score7.3", "score7.4", "score7.5")],
54          function(x) as.numeric(gsub(",", ".", x))) # Remplacer les virgules par des points
55
56 # Transformer les scores en valeurs numériques
57 data_separée$score_1 <- as.numeric(data_separée$score_1)
58 data_separée$score_2 <- as.numeric(data_separée$score_2)
59 data_separée$score_3 <- as.numeric(data_separée$score_3)
60 data_separée$score_4 <- as.numeric(data_separée$score_4)
61 data_separée$score_5 <- as.numeric(data_separée$score_5)
62 data_separée$score_6 <- as.numeric(data_separée$score_6)
63 data_separée$score_7 <- as.numeric(data_separée$score_7)

```

Annexe 2:

```

90
91 # Convertir les colonnes DOB et Date_competition en format Date JJ/MM/AAAA
92 data_separée$DOB <- as.Date(data_separée$DOB, format = "%Y-%m-%d")
93 data_separée$Date_competition <- as.Date(data_separée$Date_competition, format = "%Y-%m-%d")
94
95 # Calcul de l'âge en années
96 data_separée$Age <- floor(as.numeric(difftime(data_separée$Date_competition, data_separée$DOB, units = "days")) / 365.
97

```

Annexe 3:

```

134 # Calculer le classement par manche en fonction de la division
135 data_separée <- data_separée %>%
136   group_by(Division, Round) %>% # Par division et par manche
137   arrange(desc(Total), .by_group = TRUE) %>% # Trier par score total dans chaque manche et division
138   mutate(Classement_par_Manche = row_number()) %>% # Créer le classement par manche
139   ungroup() # Enlever le groupement à la fin
140

```

Annexe 4:

```

141
142 # Classement Final en fonction de la division
143 df_finale <- data_separée %>%
144   filter(Round == "Final") %>%
145   group_by(Division) %>%
146   arrange(desc(Total), .by_group = TRUE) %>%
147   mutate(Rank_Final = row_number()) %>%
148   ungroup()
149
150 # Classement Semifinal en fonction de la division qu'on ajoute à celui des finalistes
151 df_semi_final <- data_separée %>%
152   filter(Round == "Semifinal") %>%
153   filter(!(Athlete %in% df_finale$Athlete)) %>% # Exclure les finalistes
154   group_by(Division) %>%
155   arrange(desc(Total), .by_group = TRUE) %>%
156   mutate(Rank_Semi = row_number() + max(df_finale$Rank_Final[df_finale$Division == first(Division)], na.rm = TRUE)) %>%
157   ungroup()
158
159 # Classement Quarterfinal en fonction de la division qu'on ajoute aux semifinalistes
160 df_quarterfinal <- data_separée %>%
161   filter(Round == "Quarterfinal") %>%
162   filter(!(Athlete %in% df_finale$Athlete)) %>% # Exclure les finalistes
163   filter(!(Athlete %in% df_semi_final$Athlete)) %>% # Exclure les demi-finalistes
164   group_by(Division) %>%
165   arrange(desc(Total), .by_group = TRUE) %>%
166   mutate(Rank_Quarter = row_number() + max(df_semi_final$Rank_Semi[df_semi_final$Division == first(Division)], na.rm = TRUE)) %>%
167   ungroup()
168
169 # Fusion pour le classement total
170 df_classement_total <- df_finale %>%
171   select(Athlete, Division, Rank_Final) %>%
172   full_join(df_semi_final %>% select(Athlete, Division, Rank_Semi), by = c("Athlete", "Division")) %>%
173   full_join(df_quarterfinal %>% select(Athlete, Division, Rank_Quarter), by = c("Athlete", "Division")) %>%
174   mutate(Rank_Total = coalesce(Rank_Final, Rank_Semi, Rank_Quarter)) %>%
175   arrange(Division, Rank_Total) %>%
176   group_by(Division) %>%
177   mutate(Rank_Total = row_number()) %>%
178   ungroup()
179
180 # Ajouter les colonnes de classement à data_separée
181 data_separée <- data_separée %>%
182   left_join(df_classement_total %>% select(Athlete, Division, Rank_Total), by = c("Athlete", "Division"))
183

```