




Université
Paris Cité



RAPPORT

SAE SÉRIE TEMPORELLE



SOMMAIRE

1. Introduction

2. Pré-traitement

3. Tendance et moyennes mobiles

4. Saisonnalité et décomposition

5. Série désaisonnalisée et résidus

6. Prévisions pour 2025

7. La meilleure méthode de prévision ?

8. Conclusion

9. Répartitions des tâches

10. Annexe

1. Introduction

L'Agence américaine d'information sur l'énergie (EIA) constituant une référence majeure dans la collecte, l'analyse et la diffusion d'informations sur l'énergie. Les programmes de l'EIA couvrent des données sur le charbon, le pétrole, le gaz naturel, l'électricité, les énergies renouvelables et nucléaires.


Dans ce rapport, nous nous intéressons plus spécifiquement à l'étude de la production mensuelle de l'électricité issue de la biomasse entre 2001 et 2024. Les données étudiées sont exprimées en milliers de mégawatt-heures, ce qui permet d'analyser avec précision les fluctuations mensuelles et les tendances à long terme.

L'objectif de ce rapport est de réaliser une analyse statistique complète de cette série temporelle. Dans un premier temps, nous avons procédé au traitement des données : vérification des données et des valeurs manquantes. Aucune transformation n'a été nécessaires car nous avons un modèle additif. Mise en évidence de la tendance à l'aide des moyennes mobiles et analyse de la dynamique annuelle grâce à la régression des moyennes annuelles.

Dans un second temps nous avons élaboré trois méthodes de prévision distinctes visant à estimer la production d'électricité issue de la biomasse pour l'année 2025 : le modèle polynomial de degré 2, la méthode Sarma et la méthode Holt Winters.

Afin d'évaluer la performance de ces modèles, nous avons mis en place une procédure de validation du modèle donnant les meilleures prévisions : les données de 2001 à 2023 ont été utilisées comme données d'entraînement pour prédire l'année 2024, puis les prévisions obtenues seront comparées aux données réelles afin de calculer l'erreur quadratique moyenne (MSE).

2. Pré-traitement




```
> tableau_resume
      Indicateur      valeur
1 observations totales      288
2 valeurs manquantes        0
3      Période 2001 - 2024
```

La première étape de l'analyse a consisté à examiner la qualité des données fournies par l'EIA. Cette phase de pré-traitement est essentielle afin de garantir la fiabilité des résultats statistiques et des prévisions réalisées par la suite. Une vérification de la présence de valeurs manquantes a été effectuée sur l'ensemble de la période étudiée, de 2001 à 2024. Aucune observation manquante n'a été identifiée, ce qui garantit la complétude de la série et facilite l'analyse temporelle.

Les données ont ensuite été organisées sous forme de série temporelle mensuelle en respectant l'ordre chronologique des observations. L'analyse exploratoire de la série brute met en évidence plusieurs caractéristiques importantes de la production d'électricité issue de la biomasse. On observe une tendance globale non linéaire, caractérisée par une augmentation progressive de la production jusqu'en 2014–2015, suivie d'une décroissance régulière jusqu'en 2024.

La série présente également une saisonnalité marquée et stable dans le temps. Les variations mensuelles se répètent chaque année, ce qui indique que les effets saisonniers s'ajoutent à la tendance. Ce constat justifie le choix d'un modèle additif, sans transformation logarithmique. Le modèle retenu s'écrit $Y_t = T_t + S_t + R_t$, où Y_t représente la série observée, T_t la tendance, S_t la composante saisonnière et R_t la composante résiduelle. Cette étape confirme que la série est adaptée à une analyse classique des séries temporelles.

3. Tendances et moyennes mobiles




L'analyse de la tendance aide à mieux comprendre l'évolution de la production d'électricité issue de la biomasse sur la période étudiée. Pour atténuer les fluctuations mensuelles et visualiser la tendance de long terme, des moyennes mobiles centrées sur 12 mois ont été calculées. Cette méthode permet de lisser les variations saisonnières tout en conservant l'information sur la dynamique générale de la série.

L'examen du graphique des moyennes mobiles révèle une croissance progressive de la production de 2001 à 2014, suivie d'un déclin marqué de 2015 à 2024. Cette observation met en évidence un point de retournement autour de 2014–2015, correspondant à une modification structurelle dans l'utilisation de la biomasse. La tendance ainsi mise en évidence confirme les hypothèses formulées lors de l'analyse préliminaire.

Pour compléter cette analyse, une régression linéaire sur les moyennes annuelles a été réalisée. Ce modèle permet d'identifier de manière quantitative la tendance de long terme et de comparer les phases de croissance et de décroissance. Les résultats montrent que le coefficient de pente est positif pour la période 2001–2014 et négatif pour la période 2015–2024, ce qui corrobore le constat visuel obtenu avec les moyennes mobiles.


4. Saisonnalité et décomposition

Pour analyser la saisonnalité de la production d'électricité issue de la biomasse, une décomposition additive de la série temporelle a été réalisée. La série présente une saisonnalité stable et répétitive avec une périodicité de 12 mois. Chaque mois conserve le même coefficient d'une année sur l'autre, ce qui indique que le cycle saisonnier se répète exactement chaque année. Cette régularité facilite l'identification des périodes de pics et de creux et permet de séparer clairement les effets saisonniers de la tendance et du résidu.




La courbe des coefficients saisonniers montre une saisonnalité annuelle très marquée. Les valeurs sont les plus faibles en février et avril, tandis que les pics apparaissent en juillet et août. Entre ces extrêmes, les coefficients oscillent autour de zéro, reflétant la variation mensuelle typique par rapport à la moyenne annuelle. Cette visualisation permet d'identifier clairement les mois de creux et de pic saisonniers.

5. Série désaisonnalisée et résidus



La série désaisonnalisée correspond à la série initiale dont la saisonnalité a été retirée. Elle permet de mettre en évidence la tendance à long terme et les fluctuations irrégulières, sans être perturbée par les variations saisonnières régulières.


Les valeurs de la série désaisonnalisée restent proches de celles de la série originale, mais les pics et creux saisonniers sont atténués, ce qui rend la tendance plus claire. On observe ainsi une croissance progressive jusqu'en 2014, suivie d'une décroissance régulière jusqu'en 2024. Les variations qui subsistent reflètent les fluctuations irrégulières et les résidus aléatoires.



La décomposition permet également d'isoler les résidus, le graphique des résidus représente la composante irrégulière de la série après retrait de la tendance et de la saisonnalité. Ce graphique


nous montre bien que la décomposition additive est appropriée. La dispersion des résidus reste relativement stable au cours des années.

Quelques valeurs extrêmes apparaissent occasionnellement, dépassant deux fois l'écart-type, traduisant des fluctuations exceptionnelles.



```
Min.    : -286.620
1st Qu. : -53.386
Median  :  -1.847
Mean    :   1.241
3rd Qu. :  60.180
Max.    : 284.042
```

La moyenne (1.241) et la médiane (-1.847) sont toutes deux très proches de zéro. C'est un bon indicateur. Le modèle de décomposition semble efficace car les résidus sont bien centrés autour de zéro. Cependant, on constate la présence de valeurs aberrantes qui peuvent être des chocs ou événements non expliqués qui mériteraient d'être étudiés sur un graphique des résidus en fonction du temps.




Les boîtes à moustaches des résidus par mois permettent d'analyser la distribution des erreurs résiduelles en fonction des mois de l'année. Pour la majorité des mois la médiane est proche de zéro. On observe toutefois une dispersion légèrement plus importante pour certains mois, notamment au printemps et à l'automne, ainsi que la présence de quelques valeurs aberrantes à ces moments-là. Ce qui traduit des fluctuations exceptionnelles de la production de biomasse, qui peuvent être liées à des facteurs exogènes comme le climat, les contraintes techniques ou la variation de la demande. Cela reflète l'incertitude météorologique des saisons de transition.

6. Prévisions pour 2025

Méthode polynomiale

La première approche de prévision consiste à modéliser la tendance à l'aide d'un polynôme. Le choix d'un polynôme de degré 5 pour modéliser la tendance c'est fait grâce au critère AIC, qui évalue la qualité relative des modèles en cherchant le meilleur compromis entre la complexité et la précision de l'ajustement. C'est le polynôme qui a obtenu la valeur d'AIC la plus faible, le rendant le modèle le plus pertinent pour capturer la forme générale de la tendance de la production entre 2001 et 2024, notamment sa phase de croissance suivie de son déclin.



L'analyse de cet ajustement polynomial montre que le modèle est trop lisse pour être un outil de prévision complet de la production d'électricité, car bien qu'il réussisse à capturer la tendance générale de la série, il néglige toutes les variations à moyenne et courte échelle. La prédiction pour 2025 n'est qu'une simple extrapolation de cette tendance lissée, ce qui la rend insuffisamment précise car elle n'intègre pas les variations saisonnières attendues. En conclusion, ce polynôme est utile pour décrire la forme générale passée de la production, mais il est inadéquat pour une prévision opérationnelle sans y adjoindre d'autres composantes essentielles comme la saisonnalité.

Méthode SARMA

```
> #le modele SARMA via la fonction "auto.arima" du package forecast
> auto_sarma<-forecast::auto.arima(donnees.ts)
> prediction_auto_sarma<-predict(auto_sarma,n.ahead=12)
> prediction_auto_sarma$pred
```


	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov	Dec
2025	3982.505	3540.468	3740.465	3443.210	3737.115	3727.651	3922.239	3954.366	3600.305	3394.989	3559.422	3810.042

Ici la méthode SARMA a été réalisée à l'aide de la fonction `auto.arima` du package `forecast`, qui sélectionne automatiquement le modèle ARIMA saisonnier le plus adapté à la série étudiée. Les prévisions pour 2025 montrent une production mensuelle comprise entre 3395 et 3982 milliers de mégawatt-heures. Les valeurs les plus élevées sont observées en janvier, juillet et août, tandis

que les niveaux les plus faibles apparaissent principalement au printemps et à l'automne, notamment en avril et en octobre. Ce qui est cohérent vis-à-vis de la saisonnalité mise en évidence lors de l'analyse des coefficients saisonniers.


Globalement, les niveaux prévus pour 2025 restent relativement proches de ceux observés en 2023-2024, ce qui suggère une stabilisation de la production à un niveau bas. La méthode SARMA prolonge donc la tendance décroissante observée depuis 2016, tout en conservant des fluctuations saisonnières régulières.

Méthode Holt-Winters



Avec la prévision pour l'année 2025 obtenue à l'aide du modèle de Holt-Winters. On observe que la partie prédite s'inscrit dans le prolongement direct de la dynamique observée en fin de période, à savoir une tendance globalement décroissante. La prévision pour 2025 indique une poursuite de la baisse de la production d'électricité issue de la biomasse, déjà observée depuis environ 2016. Le modèle Holt-Winters qui prend explicitement en compte la tendance et la saisonnalité, reproduit les pics estivaux et les creux hivernaux avec une amplitude saisonnière comparable à celle des années précédentes. Les niveaux prévus pour 2025 restent semblables à 2023-2024, ce qui suggère l'absence de rupture brutale dans la dynamique de production, mais plutôt une continuité du déclin.

7. La meilleure méthode de prévision ?



En regardant seulement le graphique, on peut supposer que le meilleur modèle de prévision est celui de Holt-Winters.

Afin de déterminer la méthode de prévision la plus performante, les données de 2001 à 2023 ont été utilisées comme données d'entraînement afin de prédire l'année 2024, puis les prévisions obtenues ont été comparées aux valeurs réellement observées. La qualité des modèles a été évaluée à l'aide de l'erreur quadratique moyenne.

Les résultats obtenus sont les suivants :

```
> MSE <- data.frame( "Auto SARMA"=MSE_auto_sarma, "HW"=MSE_hw, "Mod Poly"=mse_poly)
> MSE
  Auto.SARMA      HW Mod.Poly
1  23550.95 22482.5 38130.52
```

Le modèle polynomial, bien qu'optimisé via le critère AIC, présente l'erreur la plus élevée. Ce résultat confirme les analyses précédentes : ce modèle est trop lisse et ne prend pas en compte la saisonnalité et les variations mensuelles. Il est donc peu adapté à une prévision précise à court terme.

La méthode SARMA fournit des prévisions nettement plus précises que le modèle polynomial. Elle parvient à reproduire correctement la structure saisonnière de la série et à prolonger la tendance décroissante observée depuis 2016. Toutefois, son erreur reste légèrement supérieure à celle obtenue avec le modèle Holt-Winters.

La méthode Holt-Winters présente la plus faible erreur quadratique moyenne, ce qui en fait le modèle le plus performant parmi les trois. Ce résultat s'explique par le fait que Holt-Winters modélise explicitement la tendance décroissante et la saisonnalité stable de la série.

Au regard des valeurs des erreurs quadratiques et de la cohérence des prévisions dans la série historique, la méthode Holt-Winters est retenue comme la meilleure méthode de prévision pour la production d'électricité issue de la biomasse. Elle offre le meilleur compromis.

8.Conclusion

Ce rapport a analysé la production mensuelle d'électricité issue de la biomasse aux États-Unis entre 2001 et 2024. La série montre une tendance non linéaire avec croissance jusqu'en 2014 puis déclin, ainsi qu'une saisonnalité stable et des fluctuations irrégulières limitées.

Trois méthodes de prévision ont été comparées : le modèle polynomial, le SARMA et Holt-Winters. Après validation sur les données de 2001 à 2023 pour prédire l'année 2024, Holt-Winters a présenté la plus faible erreur quadratique moyenne, intégrant correctement à la fois la tendance décroissante et la saisonnalité stable. Le modèle polynomial, trop lisse, et le SARMA, moins précis, ont montré des performances inférieures.

Ainsi, Holt-Winters est retenu comme la méthode la plus adaptée pour les prévisions 2025, car elle reproduit la dynamique observée dans les données d'entraînement et permet d'estimer la poursuite du déclin depuis 2015 avec des variations saisonnières régulières. Ce choix illustre l'efficacité des séries temporelles pour analyser et prévoir la production énergétique.

English Summary :

The report analyzes and forecasts monthly electricity production from biomass in the United States over 2001–2024 using EIA data. The series, expressed in thousands of megawatt-hours, shows a non-linear trend with growth until 2014–2015, followed by a steady decline, and stable seasonal fluctuations.

After verifying no missing values, the data were transformed into a monthly time series. Additive decomposition was applied, separating trend, seasonality, and residuals. The trend was examined with moving averages and annual mean regression, while seasonality showed regular peaks in summer and troughs in spring and autumn. Residuals were centered around zero with constant variance, confirming a good model fit despite occasional outliers.

Three forecasting methods were tested for 2025: a polynomial trend model, SARMA, and Holt-Winters. The polynomial model, though optimized with AIC, ignored seasonal effects. SARMA accounted for temporal dependence and seasonality but was less accurate. Holt-Winters achieved the lowest mean squared error on 2024 predictions and was selected as the most reliable method.

Forecasts indicate a continuation of the declining trend since 2016, with stable seasonal patterns. This study demonstrates the effectiveness of time series models for energy production analysis and forecasting while noting their limitations in handling unexpected external shocks.

Répartition des tâches

Le travail a été réalisé en collaboration étroite entre les deux membres du binôme.

Dans un premier temps, Wilma et Naba ont travaillé conjointement sur la programmation et l'implémentation du code en R. Cette phase a inclus l'importation et la mise en forme des données, l'analyse exploratoire de la série temporelle, le calcul de la tendance, de la saisonnalité, de la décomposition additive, ainsi que la mise en œuvre des différentes méthodes de prévision (modèle polynomial, SARMA et Holt-Winters) et l'évaluation des performances à l'aide de l'erreur quadratique moyenne.

Dans un second temps, la rédaction du rapport a également été réalisée de manière partagée.

- Naba s'est principalement chargée de la rédaction des parties relatives au pré-traitement des données, à l'analyse de la tendance, à la désaisonnalisation et à l'étude des résidus, la méthode de prévision du polynôme, ainsi qu'à l'interprétation graphique.
- Wilma a principalement contribué à la rédaction des sections concernant la saisonnalité et la décomposition, les méthodes de prévision SARMA et H-W, la comparaison des modèles, ainsi qu'à la mise en forme globale du document.

Les choix méthodologiques, les interprétations des résultats et les conclusions ont été discutés et validés conjointement.

Annexes

Prévision 2025 avec la méthode polynomiale

```
123 ##methode 1 modèle polynomial |
124 # --- 1. calcul du Modèle optimal et Préparation des Prédictions ---
125 n_historique <- length(donnees.ts)
126 t_historique <- 1:n_historique
127 # Détermination du degré optimal
128 aic_values <- numeric(5)
129 for (d in 1:5) {
130   modele <- lm(donnees.ts ~ poly(t_historique, d))
131   aic_values[d] <- AIC(modele)
132 }
133 aic_values
134 degre_optimal <- which.min(aic_values)
135 modele_opt <- lm(donnees.ts ~ poly(t_historique, degre_optimal))
136 # Préparation du temps total (Historique + 2025)
137 t_prediction <- (n_historique + 1):(n_historique + 12)
138 t_total <- 1:(n_historique + 12)
139 nouvelles_donnees <- data.frame(t_historique = t_total)
140 # calcul des prédictions
141 predictions_totales <- predict(modele_opt, newdata = nouvelles_donnees)
142 predictions_2025 <- predictions_totales[(n_historique + 1):length(predictions_totales)]
143 predictions_2025 #Donnees predites selon le polynome
144 # Tracer les données historiques
145 plot(t_historique, donnees.ts, type='l',
146      xlab='Année',
147      ylab='Production',
148      main=paste("Série Historique et Prédiction (Polynôme de degré", degre_optimal, ")"),
149      xaxt='n')
150
151 # Ajouter la ligne d'ajustement (courbe bleue, 2001-2024)
152 lines(t_historique, predictions_totales[1:n_historique], col='blue', lwd=2, lty=2)
153 # Ajouter la ligne de prédiction (courbe rouge, 2025)
154 lines(t_prediction, predictions_2025, col='red', lwd=2, lty=1)
155 # Ligne verticale de séparation (2024 / 2025)
156 abline(v = n_historique + 0.5, col = "gray", lty = 3)
157 # Légende
158 legend("topleft",
159      legend = c("Données historiques (2001-2024)", "Ajustement polynômial", "Prédiction 2025"),
160      col = c("black", "blue", "red"),
161      lwd = c(2, 2, 2),
162      lty = c(1, 2, 1),
163      bty = "n")
```