

Projet universitaire

Détection de profils biologiques atypiques

Naba Solly

Groupe de 4 — Janvier à Avril 2026

1 Contexte

Dans le cadre de ce projet, nous avons analysé un jeu de données portant sur le suivi biologique longitudinal de 30 individus. L'objectif était d'identifier les profils biologiques atypiques à l'aide de la méthode des Z-scores.

Deux biomarqueurs ont été analysés : la ferritine, protéine de stockage du fer, et le fer sérique, qui mesure le fer circulant dans le sang. Ces deux marqueurs, biologiquement liés, offrent ensemble une image complète du métabolisme du fer.

2 Description des données

Le jeu de données comprend deux fichiers Excel, `ferritine.xlsx` et `fer_serique.xlsx` contenant les résultats biologiques de 30 individus mesurés à plusieurs reprises dans le temps. Chaque individu possède entre 1 et 16 prélèvements, les cellules vides correspondant à des données manquantes.

3 Traitement

Les données ont été restructurées depuis un format large vers un format long, où chaque ligne correspond à une mesure avec trois variables : l'identifiant de l'individu, le nom du marqueur et la valeur du prélèvement.

Un premier constat a été la présence de 7 individus possédant moins de 3 prélèvements. Ces individus ont été exclus de l'analyse car la méthode nécessite au minimum 3 valeurs pour calculer une moyenne et un écart-type fiables. L'analyse porte donc finalement sur 23 individus.

L'analyse descriptive de la ferritine révèle :

- Distribution fortement asymétrique à droite
- Valeurs comprises entre 12 et 390 $\mu\text{g/L}$
- Médiane à 74 $\mu\text{g/L}$, moyenne à 104 $\mu\text{g/L}$ — signe de valeurs extrêmes élevant la moyenne
- Présence de plusieurs outliers détectés au boxplot

4 Méthodes

Trois méthodes basées sur les Z-scores ont été comparées. Le principe commun consiste à comparer chaque valeur d'un individu à ses propres valeurs passées. Le Z-score mesure l'écart à son comportement habituel, et la statistique retenue T_n est le maximum de ces scores, comparé à un seuil selon n et le taux de faux positifs.

- **Univariée** : chaque biomarqueur est analysé séparément, sans temporalité. Approche la plus simple et conservative.
- **Saisonnrière** : les prélèvements sont séparés en deux saisons (impairs/pairs). La variance combinée permet de distinguer variations saisonnières normales et vraies anomalies.
- **Multivariée** : les deux biomarqueurs sont analysés simultanément via une matrice de covariance, détectant des anomalies dans leur combinaison même si chaque marqueur semble normal individuellement.

5 Résultats

Les trois méthodes ont été appliquées avec un taux de faux positifs de 0,95, puis de 0,80 pour la question 11. La méthode univariée détecte uniquement l'individu 11 sur la ferritine ($T_n = 4,16 > \text{seuil } 4,12$). La méthode saisonnière détecte l'individu 25 ($T_n = 6,61 > \text{seuil } 5,07$) — l'individu 11 disparaît, son anomalie étant liée à une variation saisonnière. La méthode multivariée révèle deux nouveaux individus invisibles auparavant : l'individu 24 ($T_n = 18,8$) et l'individu 28 ($T_n = 55,8$), tous deux largement au-dessus du seuil de 16,5. Pour le fer sérique, aucune anomalie n'est détectée quelle que soit la méthode.

5.1 Impact du seuil

Methode	Biomarqueur	Anormaux à 95%	Anormaux à 80%	Difference
Univariée	Ferritine	1	2	+1
Univariée	Fer sérique	0	3	+3
Saisonnrière	Ferritine	1	3	+2
Saisonnrière	Fer sérique	0	2	+2
Multivariée	Ferritine+Fer	2	5	+3

Plus le seuil baisse, plus la détection augmente (mais avec plus de faux positifs).

6 Conclusion

Ce projet a permis de comparer trois méthodes de détection d'anomalies biologiques. Les approches sont complémentaires : la méthode univariée détecte l'individu 11, la saisonnière l'individu 25, et la multivariée les individus 24 et 28. La méthode multivariée est la plus puissante. Le choix du seuil influe directement sur les conclusions : 0,95 limite les fausses alertes, 0,80 détecte davantage. Limite principale : 7 individus exclus faute de prélèvements suffisants.

Retrouvez la présentation [ici](#).

